

基于点云神经网络的高温超导电流引线温度场重建

笃岳霖

July 31, 2026

Outline

绪论

算法介绍与结果

未来方向

参考文献

HTS 电流引线结构与边界条件




Figure 1: HTS 高温超导电流引线结构图

HTS 电流引线包括 LTS, HTS, 过渡段, HEX 段。其中 HEX 段连接了室温端与 HTS, HTS 连接了 HEX 与 LTS 段。定义 HTS 与换热器连接部位为温端, HTS 与 LTS 连接部位为冷端, 其温度通常分别为 50K 与 4.5K。

HTS 段的三种状态

- ▶ 稳态运行: 正常稳态运行条件下, 高温超导段工作于其临界温度以下, 处于完全超导态。因此不产生焦耳热, 同时热传导率很低。引线的换热器段采用气冷 (用 50 K 氦气冷却) 带走由室温端传导及自身由于电流传输的焦耳热。
- ▶ LOFA 阶段: 从低温系统停止供冷开始, 到超导叠发生失超之前的这段时间被定义为 LOFA 时间。在此基础上 HTS 段由 HEX 段的传导热导致发热。
- ▶ Burnout 阶段: Burnout 时间是从超导叠失超开始, 到热点温度达到设定阈值为止。进入该阶段后, HTS 材料失去超导性转入电阻态, 工作电流迅速分流至高温超导带的基体材料以及并联分流器中。此时 HTS 段的升温是由 HEX 段的热传导以及自身产生的焦耳热导致的。
[Cheng et al., 2025, 毕延芳 et al., 2009, Heller et al., 2011]

本实验关注点

- ▶ 如何通过极少量时间下的温度分布扩充数据集。
- ▶ 通过少量离散点的温度重建整段 HTS 导体的温度

通过 PINN 扩充实验数据集

PINN (Physics-Informed Neural Network, 物理信息神经网络) 是一种将深度学习与物理学定律 (如偏微分方程 PDE) 结合的机器学习方法, 他的创新点在于把物理规律作为正则化项直接嵌入到神经网络的损失函数中, 强迫生成数据符合物理规律
在这里我使用 PINN 的模型是 MLP, 其中输入层 2 个神经元, 内部 4 个隐藏层每层包含 64 个神经元, 最后一个输出层 (64,1) 输出在 (x, T) 下的预测温度值。




Figure 2: MLP 简介图

通过 PINN 扩充实验数据集

损失函数包括数据拟合损失和物理残差损失。

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{data}} + w_{\text{pde}} \mathcal{L}_{\text{pde}}$$

其中数据损失为


$$\mathcal{L}_{\text{data}} = \frac{1}{N} \sum (T_{\text{pred}} - T_{\text{data}})^2 \text{ (均方误差 MSE)}$$

物理损失为


$$L_{\text{pde}} = \frac{\partial T}{\partial t} - \alpha \frac{\partial^2 T}{\partial x^2}$$

在这里取 $\alpha=0.001$. 为了拟合温度分布曲线与时间输入, 让模型生成符合分布规律的数据集即可, 后期可以用真实数据对训练出来的重建温度场的模型微调。

通过 PINN 扩充实验数据集



(a) 真实 LOFA 状态下温度分布数据



(b) 生成的 LOFA 状态下温度分布数据

Figure 3: LOFA 状态下温度分布数据的真实值与 PINN 生成值对比

使用训练的模型在 0-600s 每 5s 取一次值，在每个时间点均等取值 256 个样本点作为该时间的温度分布。

使用 PointNet 基于少量离散温度点重建全局温度分布

PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation

Charles R. Qi* Hao Su* Kaichun Mo Leonidas J. Guibas
Stanford University

Figure 4: PointNet 论文

首先，点云具有三大特性：

- ▶ 无序性：点云本质上是一个点的集合，点与点之间没有固定的输入顺序。模型必须对输入顺序的 $N!$ 种排列保持不变性。
- ▶ 点间相互作用：点处于具有度量空间的欧氏空间中，相邻点会形成有意义的局部结构，因此模型需要捕获局部邻域特征。
- ▶ 变换不变性：整个点云进行整体旋转或平移时，其类别或分割结果不应改变。

[Qi et al., 2017]

如果把 HTS 的温度场视为很多个离散点，那么 HTS 的温度场也满足这三个条件。

使用 PointNet 基于少量离散温度点重建全局温度分布




Figure 5: PointNet 架构图

T-Net($N \times N$ 仿射映射矩阵) 映射 $\rightarrow$ 使用两个 MLP 将输入升维到 1024 维 $\rightarrow$ 最大池化提取最有代表性的特征。
之后如果分类任务走 MLP 输出分数，如果是分割任务就把 1024 维高维全局特征拼接到原始向量上再经过 MLP 给出属于哪个部位的打分。

使用 PointNet 基于少量离散温度点重建全局温度分布

Reconstruction and prediction of temperature distribution in Super-X superconducting magnets based on deep learning

Mingliang Liu^{a,b}, Yu Wu^a, Shuqing Zhang^c, Libiao Hu^a, Xiaohui Guan^{a,b}, Yi Shi^a,
HuaJun Liu^{a,c}, Fang Liu^{a,c}

Figure 6: Reconstruction and prediction of temperature distribution in Super-X superconducting magnets based on deep learning




Figure 7: ThermoNet 架构图

我们重构温度场使用的是上半部分的相同架构的模型
[Liu et al., 2026]

使用 PointNet 基于少量离散温度点重建全局温度分布




Figure 8: Point2Tem 模型架构图

· 上半部分是一个 PointNet 模型，经过最大池化后提取出全局特征。

然后这个全局特征 $(1, 256)$ 在经过一个线性全连接层扩展到更多维度 $(1, 256 \times 8 = 2048)$ ，并在线性层后加上 Batch 归一化与 ReLU 激活函数引入非线性能力，然后经过梯度重置形成一个类似于低分辨率图像 (256×8) 的低分辨率网格特征图。

最后把这个输入给 4 层反卷积层，分 4 步反卷积成温度分布图。

一维 HTS 电流引线分布的 PDE 损失函数推导




图 4.1 高温超导电流引线传热分析的一维模型

Figure 9: HTS 热力学分析的一维模型

首先设高温超导电流引线沿轴向为一维坐标 $x \in [0, L]$

左端 ($x = 0$): 连接 LTS (冷端), 温度保持为 T_L (4.5K)。

右端 ($x = L$): 连接 HEX (温端), 温度保持为 T_H (300K, 且 $T_H > T_L$)。

失冷状态 (LOFA): 冷却介质停流 (对流换热项 $Q_v = 0$)。在此状态下, 引线内的热量流动由右向左传导, 同时伴随电流产生的内部焦耳热以及微元自身的能量储存导致微元升温。

在引线轴向任意位置 x 处取长度为 dx 、横截面积为 A 的微元段。以 x 轴正方向作为向量基准方向列能量平衡方程。

一维 HTS 电流引线分布的 PDE 损失函数推导

传导热:

首先基础导热功率方程为 $Q(x) = -\lambda(T)A\frac{\partial T}{\partial x}$, 那么带入得到左端面 (x 处) 能量流出 Q_{in} :

$$Q_{in} = Q_x = -\lambda(T)A\frac{\partial T}{\partial x}$$

右端面 ($x + dx$ 处) 能量流入 Q_{out} (利用泰勒展开):

$$Q_{out} = Q(x+dx) = Q_x + \frac{\partial Q_x}{\partial x} dx = Q_{in} + \frac{\partial Q_{in}}{\partial x} dx = -\lambda(T)A\frac{\partial T}{\partial x} + \frac{\partial}{\partial x} \left(-\lambda(T)A\frac{\partial T}{\partial x} \right) dx$$

微元净导入导热功率:

$$\Delta Q_{cond} = Q_{in} - Q_{out} = \frac{\partial}{\partial x} \left(\lambda(T)A\frac{\partial T}{\partial x} \right) dx$$

[袁春燕 et al., 2007]

一维 HTS 电流引线分布的 PDE 损失函数推导

焦耳热：根据焦耳定律，电流 $I(t)$ 流经微元电阻 $R_{elem} = \frac{\rho(T)dx}{A}$ 产生的发热功率为：

$$Q_{joule} = I^2(t) \cdot R_{elem} = \frac{\rho(T)}{A} I^2(t) dx$$

微元升温速率：微元的能量变化率 Q_{store} 有

$$Q_{store} = mc_p(T) \frac{\partial T}{\partial t} = (\rho_m A dx) c_p(T) \frac{\partial T}{\partial t} = C(T) A dx \frac{\partial T}{\partial t}$$

其中 $C(T) = \rho_m c_p(T)$ 为材料的体积热容 ($J/(m^3 \cdot K)$)， ρ_m 为质量密度， $c_p(T)$ 为比热容。

一维 HTS 电流引线分布的 PDE 损失函数推导

能量守恒：根据能量守恒定律有

$$Q_{store} = \Delta Q_{cond} + Q_{joule}$$

$$C(T)A dx \frac{\partial T}{\partial t} = \frac{\partial}{\partial x} \left(\lambda(T) A \frac{\partial T}{\partial x} \right) dx + \frac{\rho(T)}{A} I^2(t) dx$$

假设横截面积 A 沿轴向均匀，等式两边同除以 $A dx$ ，得到一维 LOFA 暂态热传导偏微分方程 (PDE)：

$$C(T) \frac{\partial T(x, t)}{\partial t} = \frac{\partial}{\partial x} \left[\lambda(T) \frac{\partial T(x, t)}{\partial x} \right] + \frac{\rho(T)}{A^2} I^2(t)$$

一维 HTS 电流引线分布的 PDE 损失函数推导

为了把上述的 PDE 方程转化为神经网络可优化的目标，由于神经网络的目标是找到一组参数使得 $\text{Loss} \rightarrow 0$ ，那么需要把上述 PDE 方程改写成残差公式形式目标是 $R(x, t) = 0$ 。

考虑到物性参数（热导率 λ 、体积热容 C 、电阻率 ρ ）均为温度 T 的非线性函数，对导热项应用链式求导法则展开，热导率 λ 随 T 变化，而 T 又是关于 x 和 t 的方程，那么展开过程如下。

一维 HTS 电流引线分布的 PDE 损失函数推导

首先乘法求导法则 $(u \cdot v)' = u'v + uv'$: 设 $u = \lambda(T)$, 设 $v = \frac{\partial T}{\partial x}$, 则有

$$\frac{\partial}{\partial x} \left[\lambda(T) \cdot \frac{\partial T}{\partial x} \right] = \underbrace{\frac{\partial[\lambda(T)]}{\partial x}}_{\text{对 } u \text{ 求导}} \cdot \frac{\partial T}{\partial x} + \lambda(T) \cdot \underbrace{\frac{\partial}{\partial x} \left(\frac{\partial T}{\partial x} \right)}_{\text{对 } v \text{ 求导}}$$

根据链式法则, 对 $\lambda(T)$ 关与 x 求导:

$$\frac{\partial[\lambda(T)]}{\partial x} = \frac{d\lambda(T)}{dT} \cdot \frac{\partial T}{\partial x}$$

代回这一项可以得到

$$\frac{\partial}{\partial x} \left[\lambda(T) \frac{\partial T}{\partial x} \right] = \left(\frac{d\lambda(T)}{dT} \cdot \frac{\partial T}{\partial x} \right) \cdot \frac{\partial T}{\partial x} + \lambda(T) \cdot \frac{\partial^2 T}{\partial x^2} = \lambda(T) \frac{\partial^2 T}{\partial x^2} + \frac{d\lambda(T)}{dT} \left(\frac{\partial T}{\partial x} \right)^2$$

一维 HTS 电流引线分布的 PDE 损失函数推导

移项后得到 PDE 残差公式：

$$\mathbf{R}(\mathbf{x}, \mathbf{t}; \theta) = \mathbf{C}(\mathbf{T}) \frac{\partial \mathbf{T}_\theta}{\partial \mathbf{t}} - \lambda(\mathbf{T}) \frac{\partial^2 \mathbf{T}_\theta}{\partial \mathbf{x}^2} - \frac{d\lambda(\mathbf{T})}{d\mathbf{T}} \left(\frac{\partial \mathbf{T}_\theta}{\partial \mathbf{x}} \right)^2 - \frac{\rho(\mathbf{T})}{\mathbf{A}^2} \mathbf{I}^2(\mathbf{t})$$

在这里 $T_\theta(x, t)$ 表示神经网络对 (x, t) 处温度的预测值， θ 为网络参数；对于超导段，当 $T < T_{crit}$ 时 $\rho(T) = 0$ ；当失冷升温导致 $T \geq T_{crit}$ （失超）时， $\rho(T)$ 自动切换为基质金属等效电阻率。在这里由于数据集问题我们暂时只考虑在 LOFA 到失超前的温度重建与预测。

Point2Tem 训练损失函数

Point2Tem 通过最小化总损失函数 $\mathcal{L}_{total}(\theta)$ 来拟合温度场，损失函数由物理残差 Loss、初始条件 Loss、边界条件 Loss 和测量数据 Loss 四部分加权构成。其中测量数据 loss 在实验部分暂时没有加上。

$$\mathcal{L}_{total}(\theta) = w_{pde}\mathcal{L}_{pde} + w_{ic}\mathcal{L}_{ic} + w_{bc}\mathcal{L}_{bc} + w_{data}\mathcal{L}_{data}$$

Point2Tem 训练损失函数

PDE 物理残差损失 ($\mathcal{L}_{pde}$): 在时空采样域 $(x, t) \in [0, L] \times [0, t_{max}]$ 内均匀或自适应采样 N_r 个残差点, 约束求解满足物理定律:

$$\mathcal{L}_{pde} = \frac{1}{N_r} \sum_{i=1}^{N_r} |R(x_i^r, t_i^r; \theta)|^2$$

初始条件损失 ($\mathcal{L}_{ic}$): 失冷发生在 $t = 0$ 时刻, 引线的初始温度分布为已知稳态曲线 $T_0(x)$ (采样 N_{ic} 个点):

$$\mathcal{L}_{ic} = \frac{1}{N_{ic}} \sum_{j=1}^{N_{ic}} |T_{\theta}(x_j^{ic}, 0) - T_0(x_j^{ic})|^2$$

Point2Tem 训练损失函数

边界条件损失 ($\mathcal{L}_{bc}$) —核心体现右端高温：采样 N_{bc} 个时间点，强行约束神经网络在左端（冷端）和右端（温端）的预测值满足实际物理边界：

$$\mathcal{L}_{bc} = \frac{1}{N_{bc}} \sum_{k=1}^{N_{bc}} \left(\underbrace{\left| T_{\theta}(0, t_k^{bc}) - T_L \right|^2}_{\text{左端冷端温度残差}} + \underbrace{\left| T_{\theta}(L, t_k^{bc}) - T_H \right|^2}_{\text{右端温端温度残差}} \right)$$

测量数据损失 ($\mathcal{L}_{data}$)：利用真实数据中采样到的 N_{data} 个实测数据点微调模型：

$$\mathcal{L}_{data} = \frac{1}{N_{data}} \sum_{m=1}^{N_{data}} \left| T_{\theta}(x_m^d, t_m^d) - T_m^d \right|^2$$

实验中的损失函数

在实验中我采用与论文中相同的实验设置，使用 MSE 和 MAE 共同监督数据损失 $Loss_{data}$ 。

MSE Loss (均方误差) 数学定义：

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

MAE Loss (平均绝对误差) 数学定义：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$Loss_{data} = \alpha \cdot MSE + (1 - \alpha) \cdot MAE$$

其中我设置 α 为 0.7。

Point2Tem 实验结果




Figure 10: Caption

未来方向

- ▶ 1. 首先完善边界条件的损失函数
- ▶ 2. 消融实验分析不同损失函数对于训练 Point2Tem 的效果
- ▶ 3. 复现论文后续 PDEResConvLSTM-Att 模型预测温度场的工作
- ▶ 4. 基于上述 PDE 方程推导符合热力学定律的二阶卷积核算子并嵌入后续模型中

References I



Cheng, H., Wang, K., Du, S., Zhang, K., Jing, K., Ding, K., and Dong, Y. (2025).
Safety analysis of 55 ka high-temperature superconducting current lead under cooling loss condition.
Cryogenics, page 104167.



Heller, R., Fietz, W., Kienzler, A., and Lietzow, R. (2011).
High temperature superconductor current leads for fusion machines.
Fusion engineering and design, 86(6-8):1422–1426.



Liu, M., Wu, Y., Zhang, S., Hu, L., Guan, X., Shi, Y., Liu, H., and Liu, F. (2026).
Reconstruction and prediction of temperature distribution in super-x superconducting magnets based on deep learning.
Fusion Engineering and Design, 226:115694.



Qi, C. R., Su, H., Mo, K., and Guibas, L. J. (2017).
Pointnet: Deep learning on point sets for 3d classification and segmentation.
In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 652–660.



毕延芳, 丁开忠, 成安义, 周挺志, 林贤军, 沈光, 于景泽, 黄雄一, 王忠伟, and 程勇 (2009).
Iter 68 ka 高温超导特大电流引线研发.
低温物理学报, 31(1):41–45.



袁春燕, 毕延芳, and 白红宇 (2007).
68ka 高温超导电流引线热力学分析.
第八届全国低温工程大会暨中国航天低温专业信息网 2007 年度学术交流会论文集.