

基于卷积循环神经网络的 HTS 温度场预测

笃岳霖

August 21, 2026

Outline

绪论

算法介绍

实验结果与分析

未来方向

参考文献

本实验关注点

- ▶ 如何通过 ConvLSTM 根据已知时间序列预测未知时间序列
- ▶ 模型是否可以通过自回归预测长时间后的时间序列
- ▶ 模型是否可以使用增量数据微调模型

模型整体框架

首先在这一部分，我们参考论文 [Liu et al., 2026] 中除了物理约束的部分，设计了我们的模型架构。




Fig. 5. The structure diagram of PDEResConvLSTM-Att submodel. The model takes temporal temperature distributions and strongly correlated physical scalars as inputs. $M_{p,s}$ and $W_{p,c}$ denote dynamically adjusted attention weights. The output is the predicted 128×256 temperature distribution.

Figure 1: Caption

在这里我们可以认为论文中提出的 PDEResConvLSTM 部分为高维特征提取器/encoder，后续的 CBAM 以及单卷积层是降维特征输出结果的部分/decoder。

我对这个模型框架进行修改的内容为去掉了其中的物理约束部分 (ConvLSTM 模型内部硬编码以及 BiLSTM 生成调制因子的部分)。

PDEResConvLSTM 部分




Fig. 6. Structure diagram of the PDEResConvLSTM unit. In the data-processing workflow of each PDEResConvLSTM unit, H_{t-1}^{h-1} and C_{t-1}^{l-1} denote the hidden state and cell state output at the previous moment, respectively, and X_t^l denotes the input at the subsequent moment. C_t^l is the updated cell state after the residual connection, and H_t^l is the hidden state obtained after incorporating the physical-model computation.

Figure 2: Caption

论文在 PDEResConvLSTM 部分使用的主体是一个 ConvLSTM 模型，并且将其中硬编码嵌入了物理公式约束隐藏状态的输出。参考 [Shi et al., 2015] 论文中的说明如下所示。

LSTM




Figure 3: Caption

首先，LSTM 结构如上。包含细胞状态 C ，隐藏状态 h 以及输入 x 。内部包含三个门，可以视作对三个状态的一个掩码。
[Greff et al., 2016]

LSTM 的推导

遗忘门:

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + b_f)$$

计算输入门与候选细胞状态:

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + b_i)$$

$$\tilde{c}_t = \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c)$$

更新细胞状态 / 长期记忆:

$$c_t = \underbrace{f_t \circ c_{t-1}}_{\text{旧记忆遗忘}} + \underbrace{i_t \circ \tilde{c}_t}_{\text{新记忆写入}}$$

计算输出门与更新隐藏状态:

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + b_o)$$

$$h_t = o_t \circ \tanh(c_t)$$

其中 $\circ$ 表示逐元素相乘, W, b 表示权重矩阵与偏置。

LSTM 堆叠




Figure 4: Caption

下一层的 LSTM 的输出作为上一层的 X 输入。

对于位于第 l 层在时刻 t 的单个 LSTM 单元：

纵向：下方输入 $h_t^{(l-1)}$ （对于第一层，输入为原始特征 x_t ）；输出当前层的隐藏状态 $h_t^{(l)}$ 传递给上方第 $l+1$ 层。

横向：输入本层上一个时刻 $t-1$ 的隐藏状态 $h_{t-1}^{(l)}$ 和细胞状态 $c_{t-1}^{(l)}$ ；输出隐藏状态 $h_t^{(l)}$ 和细胞状态 $c_t^{(l)}$

ConvLSTM




Figure 2: Inner structure of ConvLSTM

Figure 5: Caption

将 FC-LSTM 中的权重矩阵换成一个 $i \times i$ 大小的卷积核，把 Wx 替换成 W 和 x 的卷积操作。其余模型结构与 FC-LSTM 保持一致。

PDEResConvLSTM




Fig. 6. Structure diagram of the PDEResConvLSTM unit. In the data-processing workflow of each PDEResConvLSTM unit, H^{t-1} and C^{t-1} denote the hidden state and cell state output at the previous moment, respectively, and X_t^t denotes the input at the subsequent moment. $\tilde{C}_t^t$ is the updated cell state after the residual connection, and H_t^t is the hidden state obtained after incorporating the physical-model computation.

Figure 6: Caption

在这篇论文中对比 ConvLSTM 做出了三个改进：

1. 加入了物理约束的部分：作者定义 $H_t^t = F(X_t^t, \tilde{H}_t^t)$ (疑问：作者没有显式给出 F 算子的形式，而是说要把离散的热力学公式转换成这个形式)
2. 在细胞状态中引入残差连接： $C_t^t = \text{ReLU}(C_t^{t-1} + \tilde{C}_t^t)$ 保留当前状态
3. 采用了不同大小卷积核的三个 PDEResConvLSTM

CBAM 模块

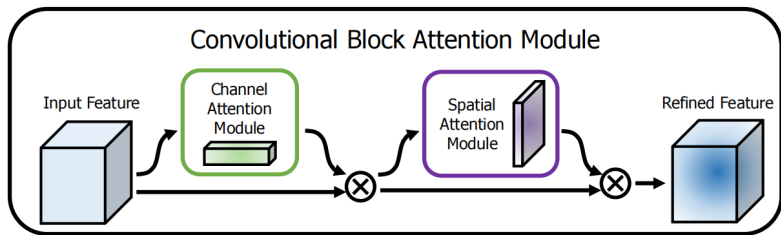


Figure 7: Caption

整体结构 [Woo et al., 2018]

通道注意力




Figure 8: Caption

通道注意力模块：哪个通道重要

$$M_c(F) = \sigma \left(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F)) \right)$$

$$M_c(F) = \sigma \left(W_1(W_0(F_{avg}^c)) + W_1(W_0(F_{max}^c)) \right)$$

空间注意力




Figure 9: Caption

空间注意力模块：哪个位置重要

$$M_s(F') = \sigma\left(\tilde{f}^{\times 7}([AvgPool(F'); MaxPool(F')])\right)$$

$$M_s(F') = \sigma\left(\tilde{f}^{\times 7}([F_{avg}^s; F_{max}^s])\right)$$

PDEResConvLSTM 中的 CBAM 模块




Fig. 7. Structural diagram of the improved CBAM unit. Input 1 is the output of the PDEResConvLSTM unit and is processed by the channel-attention and spatial-attention modules. Input 2 consists of temporal physical scalar information, including inlet/outlet temperatures and flow rate; it is fed into a BiLSTM to generate modulation factors that dynamically adjust the weights of the channel and spatial attention. The final output is obtained via a residual connection.

Figure 10: Caption

这里采用并行 CBAM 的原因是串行会导致空间注意力无法访问原特征，同时引入残差连接缓解梯度消失的问题。

模型架构图




Figure 11: Caption

这里是我简化处理的 PDEResConvLSTM 模型架构

实验设置

首先，数据集设置为步长为 1s。在输入 20 个 input steps 的情况下同时预测未来 20 个 output steps。MSE (L1) 损失，MAE (L2) 损失和梯度损失的参数分别为 0.6，0.4 和 0.05。

评估指标

MAE：所有预测点与真实点之间绝对差值的平均值，即

$$\text{MAE} = \frac{1}{N} \sum |y_{\text{true}} - y_{\text{pred}}|$$

RMSE：误差平方和平均后的平方根，即

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum (y_{\text{true}} - y_{\text{pred}})^2}。$$

MAPE：相对误差百分比的平均值，即

$$\text{MAPE} = \frac{100\%}{N} \sum \left| \frac{y_{\text{true}} - y_{\text{pred}}}{y_{\text{true}}} \right|。$$

Peak Error：所有预测点中最大的单点绝对误差，即

$$\text{Peak Error} = \max(|y_{\text{true}} - y_{\text{pred}}|)$$

模型训练 Loss 结果




Figure 12: Caption

模型收敛速度很快。

评估指标结果

0s:

MAE : 0.4149 K RMSE : 0.5834 K MAPE : 0.4299 % Peak Error :
2.5755 K

300s:

MAE : 0.4107 K RMSE : 0.6154 K MAPE : 0.4775 % Peak Error :
3.6392 K

可视化效果




Figure 13: Caption

热力图可视化误差范围




Figure 14: Caption

未来方向

- ▶ 1. 在 ConvLSTM 模型中添加物理约束的硬编码以及在 Loss 中添加 PDE 损失的软约束
- ▶ 2. 考虑能否通过添加物理约束降低自回归过程中的误差
- ▶ 3. 添加在训练完成的情况下增加新的训练数据增量学习的有关实验

References I



Greff, K., Srivastava, R. K., Koutník, J., Steunebrink, B. R., and Schmidhuber, J. (2016).

Lstm: A search space odyssey.

IEEE transactions on neural networks and learning systems, 28(10):2222–2232.



Liu, M., Wu, Y., Zhang, S., Hu, L., Guan, X., Shi, Y., Liu, H., and Liu, F. (2026).

Reconstruction and prediction of temperature distribution in super-x superconducting magnets based on deep learning.

Fusion Engineering and Design, 226:115694.



Shi, X., Chen, Z., Wang, H., Yeung, D.-Y., Wong, W.-K., and Woo, W.-c. (2015).

Convolutional lstm network: A machine learning approach for precipitation nowcasting.

Advances in neural information processing systems, 28.



Woo, S., Park, J., Lee, J.-Y., and Kweon, I. S. (2018).

Cbam: Convolutional block attention module.

In *European conference on computer vision*, pages 3–19. Springer.